

1 Универсальный метод генерации синтетических данных с выбросами

1.1 Линейные данные

1.1.1 Основная модель

Генерируется линейная зависимость с Гауссовским шумом:

$$y = ax + b + \epsilon, \quad \text{где} \begin{cases} a \sim \mathcal{U}(0.5, 3.0) \\ b \sim \mathcal{U}(-5.0, 10.0) \\ \epsilon \sim \mathcal{N}(0, \sigma^2), \sigma \sim \mathcal{U}(7, 25) \end{cases}$$

Параметры:

- Объем выборки: $N = 1000$
- Диапазон x : $[15, 85]$

1.2 Конические сечения

1.2.1 Эллипс

Параметрическое уравнение:

$$\begin{cases} x = c_x + a \cos t \cos \theta - b \sin t \sin \theta \\ y = c_y + a \cos t \sin \theta + b \sin t \cos \theta \end{cases}$$

где:

- $c_x, c_y \sim \mathcal{U}(30, 70)$
- $a, b \sim \mathcal{U}(10, 30)$
- $\theta \sim \mathcal{U}(0, \pi)$

1.2.2 Парабола

Каноническое уравнение:

$$y = A(x - h)^2 + k, \quad \text{где} \begin{cases} h \sim \mathcal{U}(30, 70) \\ k \sim \mathcal{U}(0, 100) \\ A \sim \mathcal{U}(-0.1, 0.1) \end{cases}$$

1.2.3 Гипербола

Параметрическое уравнение:

$$\begin{cases} x = h + a \cosh t \\ y = k + b \sinh t \end{cases}$$

где:

- $h, k \sim \mathcal{U}(30, 70)$
- $a, b \sim \mathcal{U}(10, 20)$

1.3 Механизмы генерации выбросов


1.3.1 Общие параметры

- Коэффициент загрязнения: $k \in \{0, 1, \dots, 13\}$
- Объем выбросов: $N_{out} = \left\lfloor \frac{50k}{1 - 0.05k} \right\rfloor$


1.3.2 Типы выбросов

Тип	Формула	Параметры
Кластерные	$\begin{cases} x \sim \mathcal{N}(\mu_x, \sigma^2) \\ y \sim \mathcal{N}(\mu_y, \sigma^2) \end{cases}$	$\mu_y = y_{true} \pm \Delta, \Delta \sim \mathcal{U}(20, 50)$
Линейные	$y = a_{out}x + b_{out} + \epsilon$	$a_{out} \sim \mathcal{U}(-3, 3), \sigma = 2.0$
Случайные	$\begin{cases} x \sim \mathcal{U}(0, 100) \\ y \sim \mathcal{U}(y_{min} - 25, y_{max} + 25) \end{cases}$	—


1.4 Примеры данных




(a) Линейные + Кластерные




(b) Эллипс + Статические




(c) Гипербола + Случайные



(d) Парабола + Линейные



(e) Эллипс + Равномерные



(f) Линейные + Ложная тенденция

2 Метрика качества аппроксимации прямой

Для оценки качества восстановления параметров прямой в двумерном случае используется специальная метрика, инвариантная к масштабу изображения и ориентации.

Метрика основана на построении описанной окружности вокруг всей гистограммы и вычислении точек пересечения этой окружности с двумя прямыми: одной с истинными параметрами, другой — с предсказанными. Пусть $\theta = (a, b)$ — параметры истинной прямой $y = ax + b$, а $\hat{\theta} = (\hat{a}, \hat{b})$ — параметры оценённой прямой $y = \hat{a}x + \hat{b}$. Тогда для обеих прямых находятся их точки пересечения с окружностью радиуса R , описанной вокруг гистограммы.

Каждая пара точек пересечения преобразуется в полярные углы относительно центра окружности. После этого вычисляются угловые расстояния между соответствующими точками, и метрика определяется как максимальное из двух таких расстояний:

$$\delta_1 = \min(|\alpha_1 - \hat{\alpha}_1|, 2\pi - |\alpha_1 - \hat{\alpha}_1|), \quad \delta_2 = \min(|\alpha_2 - \hat{\alpha}_2|, 2\pi - |\alpha_2 - \hat{\alpha}_2|),$$

$$d(\hat{\theta}) = \frac{100}{2\pi} \cdot \max(\delta_1, \delta_2)$$

Таким образом, финальное значение метрики $d(\hat{\theta})$ выражается в процентах от полного угла 2π и принимает значения от 0 (совпадение прямых) до 100 (максимальное различие).

Такой подход обеспечивает:

- инвариантность метрики к повороту;
- чувствительность к ориентации прямой и сдвигу;
- независимость от линейных размеров изображения.




Рис. 1: Дуги l_1 и l_2 между пересечениями прямых и описанной окружности

3 Методы робастной регрессии и преобразование Хафа

3.1 Робастные методы регрессии

1. **Общий принцип:** Для нахождения параметров модели минимизируется сумма функций потерь:

$$\hat{\theta} = \arg \min_{\theta} \sum_{i=1}^n \rho(r_i(\theta)), \quad r_i = y_i - f(x_i; \theta) \quad (1)$$

- (a) **Инициализация:**

- Задаётся функция потерь $\rho(r)$ с параметром устойчивости.
- Выбирается метод оптимизации

- (b) **Итеративная минимизация:**

$$\sum_{i=1}^n w(r_i^{(k)}) r_i^2 \rightarrow \min_{\theta}, \quad w(r) = \frac{1}{r} \frac{d\rho}{dr} \quad (2)$$

где k — номер итерации, $w(r)$ — веса точек

- (c) **Сходимость:**

- Обновление весов до стабилизации параметров: $\|\theta^{(k+1)} - \theta^{(k)}\| < \epsilon$
- Отбраковка выбросов (веса $w_i \approx 0$)

2. **RANSAC:**

- На каждом шаге:
 - (a) Случайно выбирается подмножество из k точек
 - (b) Строится модель по подмножеству
 - (c) Вычисляется консенсус-множество: $\{i : |r_i| < \epsilon\}$
- Финальная модель:

$$\hat{\theta} = \arg \max_{\theta} |C(\theta)|, \quad C(\theta) = \{i : |r_i(\theta)| < \epsilon\} \quad (3)$$

3. **Theil-Sen:**

- Для всех пар точек вычисляются углы наклона:

$$a_{ij} = \frac{y_j - y_i}{x_j - x_i} \quad (4)$$

- Финальная оценка:

$$\hat{a} = \text{med}(a_{ij}), \quad \hat{b} = \text{med}(y_i - \hat{a}x_i) \quad (5)$$

4. **LMedS:**

- Минимизация медианы ошибок:

$$\hat{\theta} = \arg \min_{\theta} \text{med}(r_i^2(\theta)) \quad (6)$$

- Реализация чем-то похожа на RANSAC.

3.2 Преобразование Хафа

- **Основные этапы:**

1. **Бининг:** Преобразование данных в 2D-гистограмму H_{ij} размером $n \times n$
2. **Сглаживание:** Гауссов фильтр $H' = G_{\sigma} * H =$

$$(G * I)(x, y) = \iint_{R^2} I(u, v) \cdot \frac{1}{2\pi\sigma^2} \exp\left(-\frac{(x-u)^2 + (y-v)^2}{2\sigma^2}\right) du dv =$$

$$(G * I)[x, y] = \sum_{i=-r}^r \sum_{j=-r}^r I[x-i, y-j] \cdot \frac{1}{2\pi\sigma^2} \exp\left(-\frac{i^2 + j^2}{2\sigma^2}\right)$$

3. **Аккумулятор.** Формирование аккумулятора :

$$A(\rho, \theta) = \sum_{(i,j) \in L(\rho, \theta)} H'_{ij} \quad (7)$$

4. **Детектирование:** Поиск локальных максимумов в $A(\rho, \theta)$




Рис. 2: Нахождение прямой с помощью преобразования Хафа.

Таблица 1: Сравнение робастных методов регрессии

Метод	Принцип работы	Функция потерь
Huber	Комбинирует L2 и L1 ошибки	$\rho(r) = \begin{cases} 0.5r^2, & r \leq c \\ c(r - 0.5c), & r > c \end{cases}$
Tukey	Обнуляет вклад больших ошибок	$\rho(r) = \begin{cases} c^2[1 - (1 - (r/c)^2)^3]/6, & r \leq c \\ c^2/6, & r > c \end{cases}$
Hampel	Трехступенчатая функция	$\rho(r) = \begin{cases} 0.5r^2, & r \leq a \\ a r - 0.5a^2, & a < r \leq b \\ \frac{a(c- r)^2}{2(c-b)}, & b < r \leq c \\ \text{const}, & r > c \end{cases}$
AndrewWave	Синусоидальное ослабление	$\rho(r) = \begin{cases} 1 - \cos(r/c), & r \leq \pi c \\ 2, & r > \pi c \end{cases}$
Trimmed Mean	Обрезка экстремальных значений	$\rho(r) = \begin{cases} r^2, & r \leq q_\alpha \\ 0, & r > q_\alpha \end{cases}$
RamsayE	Экспоненциальное затухание	$\rho(r) = a^{-2} \cdot (1 - e^{-a r } \cdot (1 + a r))$
Least Squares	Классический МНК	$\rho(r) = 0.5r^2$
RANSAC	Итеративно ищет наилучшую прямую	$\rho(r) = \begin{cases} 0, & r < c \\ 1, & r \geq c \end{cases}$
Theil-Sen	Медиана углов	Непараметрический метод
LMedS	Медиана ошибок	$\rho(r) = \text{med}(r_i^2)$

4 Оптимизация параметра ϵ в Huber-регрессии

4.1 Теоретические основы

Функция потерь Хьюбера:

$$\rho_\epsilon(r) = \begin{cases} \frac{1}{2}r^2, & |r| \leq \epsilon \\ \epsilon|r| - \frac{1}{2}\epsilon^2, & |r| > \epsilon \end{cases} \quad (8)$$

Стандартные рекомендации

- Классическое значение $\epsilon = 1.345$ получено из условия 95% статистической эффективности при нормальном распределении ошибок



Рис. 3: Зависимость метрики ошибки от уровня шума для разных ϵ

4.2 Экспериментальные результаты

Ключевые наблюдения

- Наилучшие результаты при $\epsilon = 0.2$:
 - Отчетлива видна прямая зависимость между метрикой и ϵ
 - Устойчивость к шуму более 25% слабая.
- Интерпретация:

Меньший $\epsilon \Rightarrow$ более агрессивное подавление выбросов

(9)

4.3 Выводы

- Эксперименты показали преимущество малых ϵ (~ 0.2) для сильнозашумленных данных
- Механизм работы:
 - При $\epsilon \rightarrow 0$: переход к LAD-регрессии (полное игнорирование выбросов)
 - При $\epsilon \rightarrow \infty$: переход к OLS (чувствительность к выбросам)

5 Оптимизация параметров преобразования Хафа

5.1 Результаты

Тестируемые значения: $n \in \{50, 100, 300, 500, 800, 1100, 1500, 2000\}$

Фиксированные параметры:

- Размер ядра сглаживания: $k = 5$
- $\sigma = 5.0$ для Гауссова фильтра
- Порог обнаружения: $threshold = 15$




Рис. 4: Зависимость метрики ошибки от уровня шума для разных n

- Оптимальные значения: $n = 300, 500$
- Очень стабильный метод. Метрика почти не зависит от уровня шума.
- При повышении n увеличивается пиксельный размер гистограммы $\Rightarrow$ увеличивается количество направлений $\Rightarrow$ есть вероятность предсказать пик не на прямой.

5.2 Выводы

- Очень стабильный метод. Может верно предсказывать даже на экстремально зашумленных данных.
- При низкой зашумленности ($\approx 10\%$) лучше использовать робастные методы регрессии.

6 Анализ результатов

В данном отчете представлен сравнительный анализ робастных методов регрессии, направленный на оценку точности восстановления линейной зависимости при различном уровне зашумленности данных. Оценка производится с помощью специальной метрики, значение которой указывает: чем **меньше** метрика, тем **лучше** качество аппроксимации. В отчете рассмотрены как классический метод наименьших квадратов (Least Squares), так и ряд робастных подходов, таких как Huber, Tukey, Hampel, AndrewWave, trimmedmean, ramsaye, Theil-Sen, RANSAC, Hough и другие.

Ниже приведен график, демонстрирующий зависимость метрики качества от уровня шума (Noise) для каждого из методов.




Рис. 5: Зависимость метрики качества от уровня шума для различных робастных методов.




Рис. 6: Тепловая карта для абсолютных погрешностей коэффициентов.

6.1 Наблюдения по уровням шума

1. Малые уровни шума (0–20%):

- Почти все методы демонстрируют низкие значения метрики, что указывает на их корректную работу в условиях незначительных выбросов.
- Особую стабильность показывают методы `hough`, `meds`.

2. Увеличение шума (30–50%):

- С повышением зашумленности большинства моделей наблюдается рост метрики, то есть ухудшение предсказаний.
- Метод `meds` очень хорошо предсказывает, но начинает резко увеличивать ошибку начиная с $\approx 40\%$ шума. Хотя пороговая точка - 50%
- Феноменальная стабильность метода с помощью БПХ.

6.1.1 Интересные наблюдения

- Робастность метода `meds` до 40% зашумленности
- М-оценки показывают похожие результаты с `RANSAC` и `Theil-Sen`
- Робастность БПХ.

6.2 Выводы

На основании анализа графика можно сделать следующие выводы:

1. **На малых уровнях шума (до 20%):** все методы, включая классический Least Squares, показывают хорошие результаты.
2. **При увеличении шума (30–50%):** М-оценки превосходят классический Least Squares. Из них наиболее устойчивыми оказались:
 - `huber`
 - `tukey`
 - `ramsaye`
3. **Лучшие методы:**
 - `meds` продемонстрировал хорошую робастность при шумах до 40%.
 - `hough` показал превосходные результаты.

7 Оценка нелинейных моделей

7.1 Математическая модель и начальные приближения

- Парабола

- Модель параболы определяется уравнением:

$$y = A \cdot (x - h)^2 + k,$$

- Для начального приближения используются:

- * $h_0 = \text{median}(x)$

- * $k_0 = \text{median}(y)$

- * $A_0 = \frac{\max(y) - \min(y)}{(\max(x) - \min(x))^2 + \varepsilon}$, где $\varepsilon = 1 \times 10^{-8}$ для предотвращения деления на ноль.

- Остаточная функция определяется как:

$$r_i = A \cdot (x_i - h)^2 + k - y_i.$$

- Эллипс

- Неявная форма уравнения эллипса:

$$\left(\frac{X'}{a}\right)^2 + \left(\frac{Y'}{b}\right)^2 = 1,$$

где координаты X' и Y' получаются посредством поворота системы координат:

$$X' = (x - c_x) \cos \theta + (y - c_y) \sin \theta,$$

$$Y' = -(x - c_x) \sin \theta + (y - c_y) \cos \theta.$$

- Начальные приближения:

- * $c_{x0} = \text{median}(x)$, $c_{y0} = \text{median}(y)$

- * $a_0 = \frac{\max(x) - \min(x)}{2}$

- * $b_0 = \frac{\max(y) - \min(y)}{2}$

- * $\theta_0 = \arctan\left(\frac{\max(y) - \min(y)}{\max(x) - \min(x)}\right)$

- Остаточная функция:

$$r_i = \left(\frac{X'_i}{a}\right)^2 + \left(\frac{Y'_i}{b}\right)^2 - 1.$$

- Гипербола

- Модель гиперболы задается уравнением:

$$\left(\frac{x - h}{a}\right)^2 - \left(\frac{y - k}{b}\right)^2 = 1.$$

- Начальное приближение включает:

- * $h_0 = \text{median}(x)$

- * $k_0 = \text{median}(y)$

- * $a_0 = \frac{\max(x) - \min(x)}{2}$

- * $b_0 = \frac{\max(y) - \min(y)}{2}$

- Остаточная функция:

$$r_i = \left(\frac{x_i - h}{a}\right)^2 - \left(\frac{y_i - k}{b}\right)^2 - 1.$$

8 Методы оптимизации

Для подгонки параметров используется функция `least_squares` с различными вариантами функции потерь (`loss`). Поддерживаются следующие функции потерь:

`soft_l1`, `huber`, `cauchy`, `arctan` — стандартные функции потерь, которые уменьшают влияние выбросов.

При использовании стандартных функций оптимизации начальное приближение подбирается автоматически, как описано выше, если пользователь не передал свои значения.

Таблица 2: Сравнение робастных методов регрессии

Метод	Принцип работы	Функция потерь
Soft_l1	Сглаженная версия L1	$\rho(t) = 2 \left(\sqrt{1 + \frac{t^2}{2}} - 1 \right)$
Huber	Комбинирует L_1 и L_2 ошибки	$\rho(t) = \begin{cases} \frac{1}{2}t^2, & \text{если } t \leq \delta, \\ \delta \left(t - \frac{1}{2}\delta \right), & \text{если } t > \delta. \end{cases}$
Cauchy	Логарифмическая функция	$\rho(t) = \frac{c^2}{2} \ln \left(1 + \frac{t^2}{c^2} \right)$
Arctan	Арктангенс	$\rho(t) = \frac{2}{\pi} \arctan(t^2)$

8.1 Подход RANSAC

Отдельное внимание уделяется варианту RANSAC для повышения робастности при наличии значительного количества выбросов. Схема RANSAC реализована следующим образом:

1. **Случайный отбор подмножества:** Для каждого типа модели выбирается минимальное число точек — для параболы $n = 3$, для эллипса $n = 5$ и для гиперболы $n = 4$.
2. **Подгонка модели:** С использованием выбранного подмножества производится оценка параметров.
3. **Оценка инлайеров:** Вычисляются остатки для всех точек. Если абсолютное значение остаточного отклонения меньше порогового значения, точка считается инлайером.
4. **Выбор лучшей модели:** Модель, давшая наибольшее число инлайеров, фиксируется как лучшая кандидатура.

9 Метрика для нелинейных моделей

- Для оценки точности предсказания кривой используется интегральная ошибка, нормированная на длину кривой. Пусть имеется истинная кривая C_{true} и предсказанная кривая C_{pred} . Каждая из кривых представляется в виде множества точек, полученных с помощью заданной функции параметризации.
- Для каждой точки $\mathbf{p} \in C_{\text{true}}$ определяется расстояние до предсказанной кривой:

$$d(\mathbf{p}, C_{\text{pred}}) = \min_{\mathbf{q} \in C_{\text{pred}}} \|\mathbf{p} - \mathbf{q}\|$$

- Далее интегральная ошибка, нормированная на длину истинной кривой, определяется как

$$E_{\text{true} \rightarrow \text{pred}} = \frac{\int_{C_{\text{true}}} d(\mathbf{p}, C_{\text{pred}})^2 ds}{\int_{C_{\text{true}}} ds},$$

где ds — элемент дуговой длины, а числитель представляет суммарную (квадратичную) ошибку между точками истинной кривой и их ближайшими точками на предсказанной кривой.

- Аналогично, вычисляется интегральная ошибка для предсказанной кривой по отношению к истинной:

$$E_{\text{pred} \rightarrow \text{true}} = \frac{\int_{C_{\text{pred}}} d(\mathbf{q}, C_{\text{true}})^2 ds}{\int_{C_{\text{pred}}} ds}.$$

- Окончательной метрикой качества предсказания является симметричная ошибка, определяемая как среднее арифметическое двух вышеуказанных ошибок:

$$E = \frac{1}{2} (E_{\text{true} \rightarrow \text{pred}} + E_{\text{pred} \rightarrow \text{true}}).$$

- Таким образом, метрика учитывает как расхождения от истинной кривой к предсказанной, так и наоборот, нормируя интегральную квадратичную ошибку на полную длину кривой, что позволяет сравнивать результаты независимо от масштаба кривой.

10 Анализ результатов для нелинейной модели

График показывает среднее значение метрики ошибки для разных методов робастной регрессии в зависимости от уровня шума (Noise). Это позволяет оценить, насколько каждая модель устойчива к выбросам.

10.1 Интерпретация моделей

arctan: Поведение метода нестабильное. Метрика резко возрастает при высоком уровне шума, особенно при Noise $\approx 47\%$, где ошибка достигает почти 390. Это указывает на низкую устойчивость к выбросам — метод «вспыхивает» при сильном зашумлении.

cauchy: Демонстрирует умеренную стабильность, хотя наблюдаются отдельные пики (например, при Noise $\approx 45\%$ метрика достигает почти 160). В целом, поведение лучше, чем у *arctan*, но остаётся чувствительным к некоторым экстремальным значениям.

huber: Относительно стабилен, значения метрики на большинстве уровней шума низкие, за исключением редких всплесков. Является одним из наиболее надёжных методов при умеренной зашумлённости.

ransac: Показывает наименьшую метрику при высоком уровне шума, значения ошибки остаются стабильными и низкими, практически без всплесков. Это самая устойчивая модель к выбросам.

soft_11: Поведение метода немного шумное, но в целом остается стабильным. Хорошая альтернатива *huber* с меньшей подверженностью сильным выбросам по сравнению с *arctan* или *cauchy*.

10.2 Выводы

- При низком уровне шума все методы (кроме **arctan**) показывают хорошие результаты, однако разница между ними становится явной при увеличении зашумлённости.
- Методы, обладающие высокой устойчивостью к выбросам (например, **ransac** и **huber**), показывают относительно стабильное поведение даже при Noise $> 30\%$.
- **soft_11** демонстрирует стабильность, оставаясь приемлемым выбором для широкого диапазона уровней шума.
- Методы **arctan** и **cauchy** менее надёжны: у **arctan** наблюдаются резкие всплески ошибки, а **cauchy** иногда даёт высокие значения метрики, особенно при сильном шуме.

Таким образом, при выборе метода для робастной регрессии в условиях зашумлённых данных рекомендуется использовать **ransac** и **huber** для экстремальных условий, а **soft_11** может быть применен в универсальных случаях.