

14.04.2025

РОБАСТНЫЕ ЭСТИМАТОРЫ

СИНТЕЗИРОВАНИЕ ЗАШУМЛЕННЫХ ДАННЫХ И РОБАСТНАЯ
ОЦЕНКА ПАРАМЕТРОВ МОДЕЛИ.

ДОКЛАДЧИК: ЦВЕТКОВ ЕГОР

С О Б Е С Е Д О В А Н И Е Н А К А Ф Е Д Р У И П И

СОДЕРЖАНИЕ

01 | Синтез данных с выбросами

02 | Метрика для линейной модели

03 | Робастные методы(1)

04 | Оптимизация параметров

05 | Анализ результатов(1)


06 | Нелинейные модели

07 | Робастные методы(2)

08 | Метрика для нелинейных моделей

09 | Анализ результатов(2)

УНИВЕРСАЛЬНЫЙ МЕТОД ГЕНЕРАЦИИ СИНТЕТИЧЕСКИХ ДАННЫХ С ВЫБРОСАМИ




Линейная модель данных

Генерируется линейная зависимость с Гауссовским шумом:

$$y = ax + b + \epsilon, \quad \text{где} \begin{cases} a \sim \mathcal{U}(0.5, 3.0) \\ b \sim \mathcal{U}(-5.0, 10.0) \\ \epsilon \sim \mathcal{N}(0, \sigma^2), \sigma \sim \mathcal{U}(7, 25) \end{cases}$$

УНИВЕРСАЛЬНЫЙ МЕТОД ГЕНЕРАЦИИ СИНТЕТИЧЕСКИХ ДАННЫХ С ВЫБРОСАМИ

ЭЛЛИПС



Нелинейные модели данных
второго порядка

Параметрическое
уравнение:

$$\begin{cases} x = c_x + a \cos t \cos \theta - b \sin t \sin \theta \\ y = c_y + a \cos t \sin \theta + b \sin t \cos \theta \end{cases}$$


УНИВЕРСАЛЬНЫЙ МЕТОД ГЕНЕРАЦИИ СИНТЕТИЧЕСКИХ ДАННЫХ С ВЫБРОСАМИ

Нелинейные модели данных
второго порядка

Уравнение параболы:


$$y = A(x - h)^2 + k, \quad \text{где} \begin{cases} h \sim \mathcal{U}(30, 70) \\ k \sim \mathcal{U}(0, 100) \\ A \sim \mathcal{U}(-0.1, 0.1) \end{cases}$$

ПАРАБОЛА



УНИВЕРСАЛЬНЫЙ МЕТОД ГЕНЕРАЦИИ СИНТЕТИЧЕСКИХ ДАННЫХ С ВЫБРОСАМИ

ГИПЕРБОЛА



Нелинейные модели данных
второго порядка

Параметрическое уравнение:

$$\begin{cases} x = h + a \cosh t \\ y = k + b \sinh t \end{cases}$$

УНИВЕРСАЛЬНЫЙ МЕТОД
ГЕНЕРАЦИИ
СИНТЕТИЧЕСКИХ ДАННЫХ
С ВЫБРОСАМИ

МЕХАНИЗМ ГЕНЕРАЦИИ
ВЫБРОСОВ

Тип	Формула	Параметры
Кластерные	$\begin{cases} x \sim \mathcal{N}(\mu_x, \sigma^2) \\ y \sim \mathcal{N}(\mu_y, \sigma^2) \end{cases}$	$\mu_y = y_{true} \pm \Delta, \Delta \sim \mathcal{U}(20, 50)$
Линейные	$y = a_{out}x + b_{out} + \epsilon$	$a_{out} \sim \mathcal{U}(-3, 3), \sigma = 2.0$
Случайные	$\begin{cases} x \sim \mathcal{U}(0, 100) \\ y \sim \mathcal{U}(y_{min} - 25, y_{max} + 25) \end{cases}$	—


МЕТРИКА КАЧЕСТВА АППРОКСИМАЦИИ ПРЯМОЙ

Для оценки качества восстановления параметров прямой в двумерном случае используется специальная метрика, инвариантная к масштабу изображения и ориентации.

$$\delta_1 = \min(|\alpha_1 - \hat{\alpha}_1|, 2\pi - |\alpha_1 - \hat{\alpha}_1|),$$

$$\delta_2 = \min(|\alpha_2 - \hat{\alpha}_2|, 2\pi - |\alpha_2 - \hat{\alpha}_2|),$$

$$d(\hat{\theta}) = \frac{100}{2\pi} \cdot \max(\delta_1, \delta_2)$$



МЕТОДЫ РОБАСТНОЙ РЕГРЕССИИ И ПРЕОБРАЗОВАНИЕ ХАФА

Робастные методы регрессии

Общий принцип:

Для нахождения параметров модели минимизируется сумма функций потерь

$$\hat{\theta} = \arg \min_{\theta} \sum_{i=1}^n \rho(r_i(\theta)), \quad r_i = y_i - f(x_i; \theta)$$

Инициализация:

- Задаётся функция потерь $\rho(r)$ с параметром устойчивости.
- Выбирается метод оптимизации

МЕТОДЫ РОБАСТНОЙ РЕГРЕССИИ И ПРЕОБРАЗОВАНИЕ ХАФА

Робастные методы регрессии

Итеративная минимизация:
где k — номер итерации,
 $w(r)$ — веса точек

$$\sum_{i=1}^n w(r_i^{(k)}) r_i^2 \rightarrow \min_{\theta}, \quad w(r) = \frac{1}{r} \frac{d\rho}{dr}$$

Сходимость:

- Обновление весов до стабилизации параметров: $||\theta^{(k+1)} - \theta^{(k)}|| < \epsilon$
- Отбраковка выбросов (веса $w_i \approx 0$)

МЕТОДЫ РОБАСТНОЙ РЕГРЕССИИ И ПРЕОБРАЗОВАНИЕ ХАФА

Робастные методы регрессии

RANSAC:

$$\hat{\theta} = \arg \max_{\theta} |C(\theta)|,$$

$$C(\theta) = \{i : |r_i(\theta)| < \epsilon\}$$

LMedS:

Реализация чем-то похожа на RANSAC

$$\hat{\theta} = \arg \min_{\theta} \text{med}(r_i^2(\theta))$$

Theil-Sen:

Для всех пар точек вычисляются углы наклона:

$$a_{ij} = \frac{y_j - y_i}{x_j - x_i}$$

Финальная оценка:

$$\hat{a} = \text{med}(a_{ij}),$$

$$\hat{b} = \text{med}(y_i - \hat{a}x_i)$$

МЕТОДЫ РОБАСТНОЙ РЕГРЕССИИ И ПРЕОБРАЗОВАНИЕ ХАФА

Преобразование Хафа

Основные этапы:

1. Гистограмма:
Преобразование данных в 2D-гистограмму

2. Сглаживание:
Свертка с гауссовским ядром

$$(G * I)[x, y] = \sum_{i=-r}^r \sum_{j=-r}^r I[x-i, y-j] \frac{1}{2\pi\sigma^2} \exp\left(-\frac{i^2 + j^2}{2\sigma^2}\right)$$

3. Аккумулятор:
Формирование аккумулятора

$$A(\rho, \theta) = \sum_{(i,j) \in L(\rho, \theta)} H'_{ij}$$

4. Детектирование:
Поиск локальных максимумов
в $A(\rho, \theta)$ 5



МЕТОДЫ РОБАСТНОЙ РЕГРЕССИИ И ПРЕОБРАЗОВАНИЕ ХАФА

Преобразование Хафа







Таблица 1: Сравнение робастных методов регрессии

Метод	Принцип работы	Функция потерь
Huber	Комбинирует L2 и L1 ошибки	$\rho(r) = \begin{cases} 0.5r^2, & r \leq c \\ c(r - 0.5c), & r > c \end{cases}$
Tukey	Обнуляет вклад больших ошибок	$\rho(r) = \begin{cases} c^2[1 - (1 - (r/c)^2)^3]/6, & r \leq c \\ c^2/6, & r > c \end{cases}$
Hampel	Трехступенчатая функция	$\rho(r) = \begin{cases} 0.5r^2, & r \leq a \\ a r - 0.5a^2, & a < r \leq b \\ \frac{a(c- r)^2}{2(c-b)}, & b < r \leq c \\ \text{const}, & r > c \end{cases}$
AndrewWave	Синусоидальное ослабление	$\rho(r) = \begin{cases} 1 - \cos(r/c), & r \leq \pi c \\ 2, & r > \pi c \end{cases}$
Trimmed Mean	Обрезка экстремальных значений	$\rho(r) = \begin{cases} r^2, & r \leq q_\alpha \\ 0, & r > q_\alpha \end{cases}$
RamsayE	Экспоненциальное затухание	$\rho(r) = a^{-2} \cdot (1 - e^{-a r } \cdot (1 + a r))$
Least Squares	Классический МНК	$\rho(r) = 0.5r^2$
RANSAC	Итеративно ищет наилучшую прямую	$\rho(r) = \begin{cases} 0, & r < c \\ 1, & r \geq c \end{cases}$
Theil-Sen	Медиана углов	Непараметрический метод
LMedS	Медиана ошибок	$\rho(r) = \text{med}(r_i^2)$

ОПТИМИЗАЦИЯ ПАРАМЕТРА ϵ В HUBER-РЕГРЕССИИ



Меньший $\epsilon \Rightarrow$ более агрессивное подавление выбросов


При $\epsilon \rightarrow \infty$: переход к OLS (чувствительность к выбросам)



ОПТИМИЗАЦИЯ ПАРАМЕТРОВ ПРЕОБРАЗОВАНИЯ ХАФА



- Очень стабильный метод. Может верно предсказывать даже на экстремально зашумленных данных.
- При низкой зашумленности ($\approx 10\%$) лучше использовать робастные методы регрессии.

Зависимость метрики от шума для разных моделей





- М-оценки показывают похожие результаты с RANSAC и Theil–Sen
- meds продемонстрировал хорошую робастность при шумах до 40%.
- hough показал превосходные результаты.

ПАРАБОЛА

- Модель параболы определяется уравнением:

$$\underline{y = A \cdot (x - h)^2 + k,}$$

- Для начального приближения используются:

$$h_0 = \text{median}(x)$$

$$* k_0 = \text{median}(y)$$

$$* A_0 = \frac{\max(y) - \min(y)}{(\max(x) - \min(x))^2 + \varepsilon}, \text{ где } \varepsilon = 1 \times 10^{-8} \text{ для предотвращения деления на ноль.}$$

- Остаточная функция определяется как:

$$\underline{r_i = A \cdot (x_i - h)^2 + k - y_i.}$$



Математическая модель и начальные приближения

ГИПЕРБОЛА

– Модель гиперболы задается уравнением:

$$\left(\frac{x-h}{a}\right)^2 - \left(\frac{y-k}{b}\right)^2 = 1.$$

– Начальное приближение включает:

- * $h_0 = \text{median}(x)$


- * $k_0 = \text{median}(y)$

- * $a_0 = \frac{\max(x) - \min(x)}{2}$

- * $b_0 = \frac{\max(y) - \min(y)}{2}$

– Остаточная функция:

$$r_i = \left(\frac{x_i - h}{a}\right)^2 - \left(\frac{y_i - k}{b}\right)^2 - 1.$$



РОБАСТНЫЕ МЕТОДЫ

- Для подгонки параметров используется функция `least_squares` с различными вариантами функции потерь (`loss`).
- Поддерживаются следующие функции потерь:
- **`soft_l1`, `huber`, `cauchy`, `arctan`** — стандартные функции потерь, которые уменьшают влияние выбросов.

Таблица 2: Сравнение робастных методов регрессии

Метод	Принцип работы	Функция потерь
Soft_l1	Сглаженная версия L1	$\rho(t) = 2 \left(\sqrt{1 + \frac{t^2}{2}} - 1 \right)$
Huber	Комбинирует L_1 и L_2 ошибки	$\rho(t) = \begin{cases} \frac{1}{2}t^2, & \text{если } t \leq \delta, \\ \delta \left(t - \frac{1}{2}\delta \right), & \text{если } t > \delta. \end{cases}$
Cauchy	Логарифмическая функция	$\rho(t) = \frac{c^2}{2} \ln \left(1 + \frac{t^2}{c^2} \right)$
Arctan	Арктангенс	$\rho(t) = \frac{2}{\pi} \arctan (t^2)$

МЕТРИКА ДЛЯ НЕЛИНЕЙНЫХ МОДЕЛЕЙ

- Для каждой точки $p \in C_{\text{true}}$ определяется расстояние до предсказанной кривой:

$$d(\mathbf{p}, C_{\text{pred}}) = \min_{\mathbf{q} \in C_{\text{pred}}} \|\mathbf{p} - \mathbf{q}\|$$

- Далее интегральная ошибка, нормированная на длину истинной кривой, определяется как:

$$E_{\text{true} \rightarrow \text{pred}} = \frac{\int_{C_{\text{true}}} d(\mathbf{p}, C_{\text{pred}})^2 ds}{\int_{C_{\text{true}}} ds},$$


где ds — элемент дуговой длины, а числитель представляет суммарную (квадратичную) ошибку между точками истинной кривой и их ближайшими точками на предсказанной кривой.

- Окончательной метрикой качества предсказания является симметричная ошибка, определяемая как среднее арифметическое двух вышеуказанных ошибок:

$$E = \frac{1}{2} \left(E_{\text{true} \rightarrow \text{pred}} + E_{\text{pred} \rightarrow \text{true}} \right).$$


- Таким образом, метрика учитывает как расхождения от истинной кривой к предсказанной, так и наоборот, нормируя интегральную квадратичную ошибку на полную длину кривой, что позволяет сравнивать результаты независимо от масштаба кривой.

Зависимость метрики от шума для разных моделей



АНАЛИЗ РЕЗУЛЬТАТОВ

- При низком уровне шума все методы (кроме `arctan`) показывают хорошие результаты, однако разница между ними становится явной при увеличении зашумлённости.
- Методы, обладающие высокой устойчивостью к выбросам (например, `ransac` и `huber`), показывают относительно стабильное поведение даже при $\text{Noise} > 30\%$.
- `soft_l1` демонстрирует стабильность, оставаясь приемлемым выбором для широкого диапазона уровней шума.
- Методы `arctan` и `cauchy` менее надёжны: у `arctan` наблюдаются резкие всплески ошибки, а `cauchy` иногда дает высокие значения метрики, особенно при сильном шуме.



THANK YOU

FOR ATTENTION



Github